

Entendimiento del negocio - Precios de Gasolina Guatemala

Entendimiento del negocio — Análisis, Extracción y Predicción de Precios de Gasolina en Guatemala

Fase 1 de CRISP-DM. Documento vivo: se actualiza cuando un supuesto se valida o se cae.

Nota de consolidación: este documento unifica y parafrasea tres versiones previas del Business Understanding (predicción de precios vía variables macro, extracción automática de precios desde tótems Shell, y el enfoque de pipeline con Florence-2 + dashboard B2B) en un solo documento coherente.

- **Fecha de la sesión:** Agosto 2026
- **Participantes:** Equipo de Data Science, Stakeholders del negocio
- **Facilitadores por tarea:** Project Manager (MLOps)
- **Escriba:** Analista de Datos
- **Versión:** 1.0 (consolidada)

Convención usada en todo el documento: [H] hecho, con fuente. [S] supuesto, con responsable y fecha límite de validación.

0. Business Model Canvas

Bloque	Contenido	Marca
Segmentos de clientes	Conductores particulares (B2C), flotas de transporte, empresas de logística (B2B) y consumidores finales interesados en anticipar y optimizar su gasto de combustible en Guatemala.	[S]
Propuesta de valor	Extracción automática de precios de combustible (Regular, Súper, V-Power, Diésel) a partir de fotografías de tótems de gasolineras (inicialmente Shell), combinada con predicción de precios futuros y alertas de tendencia, para optimizar el momento y lugar de carga y reducir el gasto de flotas.	[H]
Canales	Dashboard interactivo (BI & Reporting), API de ingesta/consulta para sistemas ERP, alertas por app móvil o mensajería (correo, WhatsApp/Telegram).	[S]
Relación con clientes	Consulta de pronósticos y tendencias, servicio automatizado tipo SaaS con alertas proactivas y no invasivas; configuración inicial única y luego automática.	[S]
Fuentes de ingreso	No aplica en la etapa académica. Posible modelo de suscripción mensual (tiered pricing) para flotas empresariales en fases posteriores.	[S]
Recursos clave	Repositorio de fotografías de tótems, modelo de visión para detección y extracción (Vision Transformers/YOLO, Florence-2, OCR), datos históricos de precios, variables internacionales (WTI, Brent, tipo de cambio), pipeline de datos por capas (Bronze/Silver/Gold), cómputo GPU (local y Colab T4), herramientas de ML.	[H]
Actividades clave	Recolección de fotografías, extracción de precios por visión/OCR, limpieza y consolidación de datos, análisis exploratorio, entrenamiento y validación de modelos predictivos, generación de alertas y pronósticos, actualización continua del histórico.	[H]
Socios clave	MEM (Ministerio de Energía y Minas), Banco de Guatemala, EIA, refinerías y proveedores logísticos, fuentes de noticias internacionales, usuarios que aportan fotografías (crowdsourcing) y plataformas cloud (GCP/AWS/Colab).	[S]

Bloque	Contenido	Marca
Estructura de costos	Tiempo del equipo, cómputo (GPU para entrenamiento e inferencia), almacenamiento de datos por capas, mantenimiento MLOps, posibles APIs.	[S]

1.1 Objetivos de negocio

Background

El precio de la gasolina en Guatemala depende del mercado internacional, los costos de importación, el tipo de cambio y factores logísticos; eventos internacionales (conflictos, sanciones, interrupciones de suministro) pueden generar variaciones significativas. Hoy la información de precios no está centralizada ni disponible de forma oportuna: registrar la evolución diaria o semanal de los distintos tipos de gasolina (Regular, Súper, V-Power, Diésel) en las estaciones requiere observación y anotación manual, un proceso lento y no escalable.

El proyecto busca resolver ambos problemas a la vez: (1) automatizar la extracción de precios directamente desde fotografías tomadas a los tótems de las gasolineras, construyendo así una base histórica confiable y continua, y (2) combinar esa base con variables económicas e indicadores internacionales para anticipar el comportamiento futuro del precio, apoyar decisiones de compra o presupuesto, y —en el caso de flotas— optimizar el momento y lugar de carga.

Objetivos de negocio

#	Objetivo	Línea base	Meta	Marca
N1	Automatizar la extracción de precios de combustible desde fotografías de tótems.	0% automatizado (ingreso enteramente manual).	≥90% de los precios extraídos de fotos sin intervención humana.	[S]
N2	Construir una base de datos histórica robusta y consolidada de precios (arquitectura Bronze/Silver/Gold).	Información dispersa, esporádica o con retrasos.	Dataset limpio, versionado y actualizado de forma recurrente, con al menos un registro confiable semanal por tipo de combustible.	[H]
N3	Predecir el precio de la gasolina (Regular, Súper, V-Power y Diésel).	No existe modelo formal.	Pronóstico a 1, 2 y 4 semanas (horizonte corto equivalente ~7 días).	[S]
N4	Detectar tendencia de alza, baja o estabilidad.	Análisis manual y reactivo.	Generar una señal automática de tendencia.	[S]
N5	Incorporar eventos y variables internacionales al modelo de predicción.	No existe integración sistemática.	Convertir indicadores y noticias en variables (features) útiles para el modelo.	[S]
N6	Reducir el gasto de combustible en flotas afiliadas optimizando el momento y lugar de carga.	Gasto mensual actual sin alertas.	Reducción del 5–8% del costo total.	[S]

Criterios de éxito de negocio

#	Criterio	Cómo se mide	Quién lo firma
C1	El modelo genera pronósticos útiles.	Comparación contra el precio real observado.	Equipo / Profesor
C2	Mejora un modelo simple (baseline).	Menor error que usar el último precio conocido.	Equipo / Profesor
C3	Explica los principales factores de cambio de precio.	Identifica variables que impulsan alza o baja.	Equipo / Profesor
C4	Reducción de tiempo en el levantamiento de datos.	Tiempo invertido baja de minutos por registro manual a segundos por procesamiento fotográfico.	Responsable del equipo
C5	Adopción de la plataforma por usuarios B2B.	Número de empresas activas en el dashboard a los 3 meses de despliegue.	Director Comercial
C6	Latencia y disponibilidad de la información.	Tiempo entre captura de la foto/actualización de datos y disponibilidad del precio o pronóstico en el dashboard (objetivo: < 1 hora).	Project Manager

1.2 Evaluación de la situación

Inventario de recursos

Recurso	Tipo	Disponibilidad	Marca
Precios nacionales (MEM u otras fuentes oficiales)	Datos	Público	[H]
Tipo de cambio (Banco de Guatemala)	Datos	Público	[H]
WTI, Brent y precios internacionales de gasolina	Datos	Público	[H]
Noticias e indicadores internacionales	Datos	Por definir / filtrar	[S]
Repositorio de fotografías de tótems (inicialmente Shell)	Datos (cruda)	Limitada, en recolección (requiere trabajo de campo)	[S]
Modelo Florence-2 / Vision Transformers / YOLO	Cómputo / Modelo	Disponible vía HuggingFace, aún sin validar a fondo	[H] / [S]
Google Colab GPU T4 y hardware local (Linux)	Infraestructura	Disponible para experimentación e inferencia	[H]
Python / Jupyter	Software	Disponible	[H]
Herramientas de ML (scikit-learn, XGBoost, LightGBM)	Software	Disponible	[H]
Conocimiento especializado en Vision Transformers e IA	Persona	Alta	[H]

Requisitos y restricciones

- Trabajar inicialmente con frecuencia semanal (o diaria, si la calidad de los datos lo permite).
- Evitar el uso de información futura en el entrenamiento (validación temporal estricta, sin leakage).
- Priorizar fuentes gratuitas y públicas.
- Las noticias e indicadores externos pueden contener ruido o duplicidad; requieren filtrado y clasificación.
- Una red neuronal (LSTM u otra) se evaluará solo si mejora de forma clara los resultados de modelos más simples.
- El pipeline debe permitir trazabilidad de las transformaciones de datos.
- **Calidad de imagen:** las fotografías se toman en calle, con ángulos, iluminación y posibles oclusiones (árboles, cables, reflejos) variables; el pipeline requiere imágenes suficientemente legibles para que el OCR/VQA funcione.
- **Privacidad:** el sistema no debe almacenar placas de vehículos ni rostros de personas que aparezcan de fondo en la fotografía de la gasolinera.
- **Interfaz de extracción:** el sistema debe poder recibir una imagen, procesarla y devolver un formato estructurado (tipo de combustible → precio).
- **Infraestructura:** la inferencia de modelos multimodales de visión requiere aceleración por hardware (GPU).

Supuestos

#	Supuesto	Responsable	Valida antes de	Estado
S1	Se predecirá inicialmente gasolina Regular, con posibilidad de extender a Súper, V-Power y Diésel.	Equipo	Fase 2	Abierto
S2	El horizonte de predicción será de 1, 2 y 4 semanas.	Equipo	Fase 2	Abierto
S3	Los factores internacionales (petróleo, tipo de cambio, eventos) tienen relación medible con el precio local.	Equipo ML	Fase 5	Abierto
S4	Existe suficiente historia de precios para entrenar y validar modelos con rigor temporal.	Equipo de datos	Fase 2	Abierto
S5	Es viable obtener y mantener actualizados los datos de fuentes públicas de forma recurrente.	Data Engineer	Fase 3	Abierto
S6	Los tótems de la red Shell mantienen un patrón y un orden fijo (V-Power, Súper, Regular, Diésel), lo que permite emparejar precio con tipo de combustible por posición.	Equipo de visión	Fase 2	Abierto
S7	La resolución de las cámaras (móviles o de campo) es suficiente para capturar nítidamente los displays LED/impresos de los tótems.	Equipo de visión	Fase 2	Abierto
S8	Los usuarios o un proceso automatizado proveerán suficientes fotos diarias para mantener actualizada la base de datos.	Data Engineer	1 mes	Abierto
S9	El mercado guatemalteco tiene variabilidad de precio suficiente para justificar un modelo predictivo.	Data Analyst	2 semanas	Abierto

Riesgos y contingencias

#	Riesgo	Probabilidad	Impacto	Contingencia
R1	Pocos datos históricos o series incompletas.	Media	Alto	Usar modelos más simples y ampliar fuentes.
R2	Ruido en noticias o indicadores externos.	Media	Medio	Filtrar, clasificar eventos y validar impacto.
R3	Sobreajuste a periodos específicos.	Alta	Alto	Validación temporal estricta y comparación rigurosa con baseline.
R4	Eventos extremos no vistos en el histórico.	Media	Alto	Reportar rangos de incertidumbre y no confiar solo en el punto estimado.
R5	Cambios de metodología o retrasos en fuentes oficiales.	Media	Medio	Documentar fuentes y tener planes de respaldo de datos.
R6	Falla de lectura (OCR/VQA) por resplandor del sol sobre el tótem, paneles LED parpadeantes o mala calidad de imagen (lluvia, reflejos).	Alta	Alto/Medio	Preprocesamiento intensivo de imágenes (escala de grises, contraste, binarización adaptativa) y validación estadística de anomalías en la capa Silver del pipeline.
R7	Cambios repentinos en el diseño del tótem o daños físicos en el panel de precios.	Media	Medio	Reglas de validación post-extracción para rechazar precios ilógicos (saltos de precio irreales).

Terminología

Término	Definición acordada
Precio objetivo	Precio futuro del combustible que se desea estimar.
Horizonte	Número de semanas hacia el futuro de la predicción.
Evento internacional	Hecho que puede afectar oferta, demanda o costos del combustible.
Baseline	Modelo simple de referencia (último precio conocido).
Señal de tendencia	Clasificación de alza, baja o estabilidad en el horizonte.
Tótem	Estructura vertical en las gasolineras, visible desde la calle, que exhibe los precios vigentes de los combustibles al público.
OCR	Optical Character Recognition (Reconocimiento Óptico de Caracteres); tecnología para extraer texto de imágenes.
V-Power / Súper / Regular / Diésel	Clasificación comercial de los tipos de combustible en Guatemala.

Costos y beneficios

Concepto	Tipo	Estimado	Marca
Tiempo del equipo	Costo	Por estimar	[S]
Cómputo y almacenamiento (GPU, capas Bronze/Silver/Gold)	Costo	Bajo / moderado	[S]
Esfuerzo de recolección inicial de imágenes (trabajo de campo)	Costo	Medio	[S]
Mejor planificación de gastos	Beneficio	Por medir	[S]
Anticipación de cambios de precio	Beneficio	Por medir	[S]
Ahorro de esfuerzo analítico frente al levantamiento manual	Beneficio	Alto	[S]
Base para análisis competitivo y predictivo	Beneficio	Alto	[S]

1.3 Objetivos de minería de datos

Traducción de negocio a ML

Objetivo de negocio	Tarea de ML	Unidad de predicción	Marca
N1 (Automatizar extracción)	Detección de objetos (Bounding Boxes) + Extracción (OCR/VQA)	Una imagen de tótem → pares (tipo de combustible, precio)	[S]
N2 (Base histórica)	Pipeline de datos / extracción tabular	Dataset limpio y versionado, precios diarios/semanales en GTQ	[H]
N3 (Predicción de precio)	Regresión / Series temporales	Precio semanal (Q/galón) a 1, 2 y 4 semanas	[S]
N4 (Tendencia)	Clasificación	Alza / Baja / Estabilidad	[S]
N5 (Variables internacionales)	Extracción / Feature engineering (posible NLP)	Variables de eventos e indicadores internacionales	[S]
N6 (Optimización de flotas)	Regresión / Series temporales aplicada	Precio futuro (Q/galón) usado como insumo de recomendación de carga	[S]

Enfoque de modelado

Se compararán varios enfoques, en dos frentes complementarios:

Extracción de precios desde imagen: 1. Detección de la región del tótem/precio con Vision Transformers o YOLO. 2. Extracción del texto/valor con OCR clásico (Tesseract, EasyOCR) o con un modelo de visión-lenguaje (Florence-2 / VQA). 3. Preprocesamiento de imagen con OpenCV (corrección de perspectiva, contraste, filtros morfológicos) antes del OCR.

Predicción del precio futuro: 1. **Baseline:** último precio conocido (naive / persistencia). 2. **Modelos de series temporales:** SARIMAX u equivalentes. 3. **Modelos de machine learning tabular:** XGBoost o LightGBM. 4. **Redes neuronales (LSTM u otras):** solo si los datos son suficientes y mejoran el baseline de forma clara.

Las variables candidatas para la predicción incluyen: precios históricos locales (extraídos del pipeline de visión), precios internacionales (WTI, Brent, gasolina de referencia), tipo de cambio, e indicadores o eventos

internacionales clasificados por tipo, relevancia, impacto esperado (alcista/bajista/neutral) y severidad.

Criterios de éxito técnicos

#	Métrica	Umbral	De dónde sale el umbral
T1	F1-Score en detección de región del precio (Bounding Box)	> 0.90	Requisito indispensable: si el modelo no ubica la zona del precio, el OCR leerá información irrelevante del fondo.
T2	Accuracy del OCR/VQA numérico (precisión de extracción)	> 0.95	Se toleran muy pocos errores; un dígito mal leído contamina la serie temporal de precios.
T3	MAE (Error Absoluto Medio) del pronóstico	Por definir (debe mejorar el baseline); referencia: < Q0.50/galón	Comparación directa contra el modelo naive; que la recomendación de ruta/carga siga siendo rentable considerando el desvío.
T4	MAPE / WAPE	Por definir	Según la variabilidad histórica observada.
T5	Exactitud de la señal de tendencia	Por definir	Debe superar una predicción simple de tendencia.

Costo asimétrico de los errores

Hay dos frentes donde el costo de los errores es asimétrico y deben tratarse de forma diferenciada:

- **En la extracción de precios:** un **falso positivo de lectura** (por ejemplo, leer “88.99” en vez de “33.99”) es mucho más costoso que un **falso negativo** (no lograr leer el precio por deslumbramiento o mala calidad de imagen). Un valor atípico contamina las estadísticas y el promedio histórico del dataset, mientras que un registro “nulo / no leído” puede interpolarse fácilmente con los precios de días adyacentes. El modelo de extracción debe operar con un nivel de confianza estricto y descartar antes que inventar.
- **En la predicción de precio futuro:** subestimar una subida fuerte suele ser más costoso que sobreestimar ligeramente el precio, ya que afecta presupuestos y decisiones de compra o de carga. Este desbalance se considerará al interpretar los resultados y, si es pertinente, al diseñar la función de pérdida o las reglas de decisión.

1.4 Plan del proyecto

Fase CRISP-DM	Duración estimada	Responsable	Entregable
1. Entendimiento del negocio	1 semana	Project Manager / Equipo	Este documento
2. Entendimiento de los datos	2 semanas	Equipo de datos	Notebook de análisis (EDA) + dataset de fotos etiquetado y revisado
3. Preparación de datos	2–3 semanas	Equipo de datos	Dataset limpio, pipeline reproducible y pipeline de preprocesamiento de imágenes funcional
4. Modelado	3 semanas	Equipo ML	Modelo de extracción (visión) afinado + modelos de predicción entrenados y comparados
5. Evaluación	1 semana	Equipo	Reporte de métricas frente a baseline y criterios T1–T5
6. Despliegue	1–2 semanas	Equipo	API REST, dashboard de monitoreo y/o script automatizado de exportación al histórico

Puntos de retorno esperados

- Volver a datos si se detectan problemas graves de calidad o cobertura, o si el preprocesamiento no logra recuperar los números de las pantallas LED (flickering), lo que obligaría a estandarizar un método de captura.
- Volver a preparación si las variables construidas no son válidas o introducen leakage.
- Volver a modelado si ningún enfoque de predicción supera de forma clara el baseline.

Herramientas y técnicas

Herramienta	Para qué	Justificación
Arquitecturas de Vision Transformers y/o YOLO	Detección de objetos	Ubican con alta precisión espacial el panel donde está el tipo de gasolina y su precio.
Florence-2 / modelos VQA	Extracción de precios (visión-lenguaje)	Alternativa a OCR clásico para leer precio y etiqueta de forma conjunta.
Python + OpenCV	Procesamiento de imágenes	Estandarización de tamaño, corrección de perspectiva y filtros previos al OCR.
Tesseract / EasyOCR	Extracción de texto	Soluciones optimizadas para convertir el fragmento aislado del tótem en texto digital.
Python	Análisis y modelado	Ecosistema estándar de ML.
Jupyter	Exploración y documentación	Reproducibilidad.
pandas	Preparación y manipulación	Manejo eficiente de datos tabulares.
scikit-learn	Evaluación y modelos base	Métricas y pipelines.
XGBoost / LightGBM	Predicción tabular	Buen desempeño en datos estructurados.
Git / GitHub	Versionado	Control de cambios y colaboración.
Fuentes oficiales (MEM, Banguat, EIA)	Datos de precios y macro	Transparencia y trazabilidad.

Decisiones abiertas

#	Decisión	Postura A	Postura B	Qué evidencia la resuelve
D1	Productos a modelar	Solo gasolina Regular	Incluir Súper, V-Power y Diésel	Disponibilidad y calidad de datos + tiempo
D2	Frecuencia	Semanal	Diaria (si es viable)	Calidad y granularidad de las fuentes
D3	Tipo de modelo prioritario para predicción	ML tradicional / series temporales	Red neuronal	Resultados de evaluación vs. baseline
D4	Uso de noticias	Solo indicadores numéricos	Incluir NLP / clasificación de eventos	Mejora real del error de predicción
D5	Emparejamiento de precio con tipo de combustible	Asumir orden rígido (Top-Bottom: V-Power, Súper, Regular, Diésel) y emparejar por posición	Entrenar un modelo que lea tanto la etiqueta del combustible como el precio simultáneamente	Análisis manual de una muestra de tótems; si el orden topológico varía, la Postura A se descarta

Cierre de la fase

1. **¿Qué decisión de negocio cambia por tener este modelo?** Se transiciona de una visibilidad esporádica y costosa (registro manual) a un flujo continuo y automatizado de datos de mercado, que permite anticipar cambios de precio y mejorar el momento de carga o la planificación de presupuestos —tanto para consumidores particulares como para flotas—, en lugar de reaccionar solo cuando el precio ya se movió.

2. **¿Cómo se vería el fracaso, en números?**

- El modelo de predicción no supera el baseline de persistencia (último precio conocido).
- MAE del pronóstico superior a Q1.00 por galón, o tasa de extracción exitosa inferior al 60% por imagen.
- Más del 10% de los registros del histórico con anomalías graves en el precio extraído (desviaciones irreales frente a la media del mercado).
- El modelo no aporta una señal de tendencia confiable.

3. **Tres supuestos críticos:**

- Existe suficiente información histórica de calidad, y es posible reconstruirla o alimentarla de forma continua a partir de las fotografías.
- Los factores internacionales tienen relación real con el precio local, y los precios fluctúan lo suficiente para que la predicción genere valor (ahorro o mejor planificación).
- Es viable capturar y leer con exactitud suficientes imágenes representativas del mercado guatemalteco de forma sostenible, y el modelo de visión (Florence-2 u otro) generaliza sobre el formato real de los tótems.

Revisión de coherencia

Chequeo	Resultado
Objetivos medibles	Sí (umbrales técnicos finos pendientes de fijar tras el EDA y la prueba piloto de extracción)
Criterios con responsable	Sí (equipo / profesor / Director Comercial / Project Manager)
Objetivos ML ligados al negocio	Sí
Riesgos con contingencia	Sí
Supuestos identificados	Sí
Decisiones abiertas documentadas	Sí